

# Road Damages Detection Using YOLOv8

Farhan Faturahman  
Telkom University  
Bandung, 40257 Indonesia  
1301213188

Gevin Latifan Abduldjalil  
Telkom University  
Bandung, 40257 Indonesia  
1301213541

Rizal Hidayat Putra  
Telkom University  
Bandung, 40257 Indonesia  
1301213444

## Abstract

*Kerusakan jalan, seperti retakan, lubang, dan deformasi permukaan, memiliki dampak signifikan terhadap keselamatan transportasi dan biaya pemeliharaan jalan. Proyek ini bertujuan untuk mengatasi tantangan tersebut dengan menggunakan YOLOv8, sebuah kerangka kerja deteksi objek terkini, untuk mendeteksi dan mengklasifikasikan berbagai jenis kerusakan jalan. Dengan memanfaatkan dataset Road Damages Detection v7 yang telah melalui tahap pra-pemrosesan dengan objek terisolasi, model kami menunjukkan tingkat presisi dan recall yang tinggi, mencapai skor mean Average Precision (mAP50-95) sebesar 91,1%. Model ini juga diintegrasikan ke dalam prototipe aplikasi web, yang memungkinkan pengguna untuk mengunggah gambar kerusakan jalan terisolasi untuk dideteksi. Hasil ini menegaskan potensi sistem untuk diterapkan dalam dunia nyata, meningkatkan efisiensi inspeksi jalan dan mengurangi biaya pemeliharaan jangka panjang.*

**Keywords:** Deteksi Kerusakan Jalan, YOLOv8, Deteksi Objek, Deep Learning, Pemeliharaan Infrastruktur

## 1. Introduction

Infrastruktur jalan merupakan komponen vital dalam mobilitas perkotaan dan pedesaan. Kerusakan seperti retakan, lubang, dan deformasi permukaan tidak hanya mengancam keselamatan pengguna jalan tetapi juga meningkatkan biaya pemeliharaan jika tidak segera ditangani. Kerusakan ini berkontribusi pada peningkatan risiko kecelakaan lalu lintas, percepatan keausan kendaraan, serta memperpanjang waktu perbaikan. Inspeksi manual, sebagai pendekatan tradisional, membutuhkan sumber daya yang besar, lambat, dan rentan terhadap kesalahan manusia. Keterbatasan ini menuntut adanya sistem otomatis yang akurat dan efisien [1][2].

Kemajuan pesat dalam bidang visi komputer dan deep learning telah membuka jalan bagi sistem deteksi kerusakan jalan yang otomatis. Namun, banyak solusi yang ada saat ini menghadapi kendala pada dataset yang tidak konsisten, biaya komputasi yang tinggi, dan keterbatasan

skalabilitas. Proyek ini mengatasi tantangan tersebut dengan menggunakan YOLOv8, sebuah kerangka kerja deteksi objek berbasis Convolutional Neural Network (CNN). Dengan memanfaatkan kemampuan pemrosesan waktu nyata serta dataset Road Damages Detection v7 yang telah diproses ulang, proyek ini bertujuan untuk mengembangkan solusi yang andal yang dapat:

- Mengotomatisasi deteksi kerusakan jalan dengan tingkat presisi dan recall yang tinggi.
- Meningkatkan efisiensi inspeksi infrastruktur.
- Menjadi dasar untuk mengintegrasikan solusi otomatis ke dalam alur kerja pemeliharaan jalan.

YOLOv8 dipilih dibandingkan model alternatif seperti Faster R-CNN dan SSD karena memiliki keseimbangan yang lebih baik antara kecepatan dan akurasi. Meskipun Faster R-CNN menawarkan tingkat presisi yang tinggi, model ini memiliki waktu inferensi yang lambat, sehingga kurang cocok untuk aplikasi waktu nyata. Sebaliknya, SSD, meskipun lebih cepat, sering kali kurang mampu mendeteksi objek kecil, yang sangat penting dalam deteksi kerusakan jalan. Arsitektur YOLOv8 yang ringan dan kemampuan ekstraksi fitur yang efisien menjadikannya pilihan optimal untuk proyek ini, terutama ketika dipasangkan dengan dataset pra-pemrosesan yang mengurangi gangguan dan meningkatkan akurasi deteksi. Keputusan ini selaras dengan temuan dari studi sebelumnya yang menyoroti kemampuan YOLO dalam menangani dataset dengan variabilitas tinggi secara efektif [3][4].

Dataset Road Damages Detection v7 yang telah diproses ulang berperan penting dalam memastikan kinerja deteksi yang tinggi dengan mengatasi ketidakseimbangan kelas dan gangguan data. Teknik pra-pemrosesan untuk mengisolasi objek dalam dataset ini memungkinkan YOLOv8 untuk fokus pada fitur kerusakan, meningkatkan efisiensi pembelajaran dan akurasi deteksi. Teknik ini sejalan dengan temuan dari [3][4] yang menekankan pentingnya kualitas dataset dalam mendukung sistem deteksi yang efisien dan dapat diskalakan.

Paper ini memberikan analisis mendalam tentang metodologi, eksperimen, dan hasil yang diperoleh, menunjukkan implikasi praktis dari sistem yang diusulkan. Temuan ini menegaskan potensi penerapan teknologi ini untuk meningkatkan keselamatan transportasi dan

mengurangi biaya pemeliharaan jangka panjang.

## 2. Related Work

Deteksi kerusakan jalan telah menarik perhatian yang signifikan dalam beberapa tahun terakhir karena kemajuan dalam deep learning. Kontribusi penting meliputi:

- **Arya et al. [1][2]:** Mengembangkan sistem deteksi kerusakan jalan global dengan dataset yang dianotasi, yang menangani variasi kondisi jalan di berbagai wilayah.
- **Naddaf-Sh et al. [3]:** Menekankan pendekatan yang efisien dan skalabel untuk deteksi kerusakan jalan, dengan menyoroti kebutuhan akan dataset berkualitas tinggi dan model ringan untuk aplikasi dunia nyata.
- **Angulo et al. [4]:** Memperkenalkan metode akuisisi data yang skalabel yang disesuaikan untuk penerapan di dunia nyata, dengan fokus pada anotasi gambar dan integrasi sensor.
- **Rateke et al. [5]:** Mengeksplorasi deteksi kerusakan dalam berbagai kondisi lingkungan, menyoroti tantangan dalam pencahayaan dan cuaca.
- **Arya et al. [6]:** Memperkenalkan RDD2020, sebuah dataset yang dianotasi secara komprehensif yang memfasilitasi kemajuan signifikan dalam deteksi kerusakan jalan dengan meningkatkan konsistensi dan cakupan data.

Meskipun berbagai upaya telah dilakukan, masih ada kesenjangan dalam mencapai kinerja tinggi di berbagai dataset. Dataset Road Damages Detection v7, dengan fokus pada objek terisolasi, mewakili peningkatan signifikan dalam mengatasi ketidakseimbangan kelas dan gangguan pada data pelatihan. Dengan mengintegrasikan dataset ini dengan YOLOv8, pendekatan kami membangun penelitian yang ada sambil memperkenalkan peningkatan dalam presisi, recall, dan efisiensi komputasi [3][4].


## 3. Data

### Dataset Overview

Dataset Road Damages Detection v7, yang berasal dari Roboflow Universe [7], mencakup 3.506 gambar yang dianotasi dengan tujuh kelas kerusakan jalan:

#### 1. D00: Longitudinal Crack


Retakan linear sepanjang permukaan jalan.



**Gambar 1 Contoh Data D00**

#### 2. D10: Transverse Crack


Retakan horizontal yang sering melintasi jalan.



**Gambar 2 Contoh Data D10**

#### 3. D20: Alligator Crack


Retakan yang saling terhubung menyerupai kulit alligator.



**Gambar 3 Contoh Data D20**

#### 4. D40: Pothole

Depresi atau lubang pada permukaan jalan.



**Gambar 4 Contoh Data D40**

#### 5. D43: White Line Blur

Garis marka jalan yang kabur.



**Gambar 5 Contoh Data D43**

#### 6. D44: Cross Walk Blur


Garis penyeberangan pejalan kaki yang pudar.



**Gambar 6 Contoh Data D44**

#### 7. D50: Manhole Cover (TBC)

Penutup saluran air berbentuk lingkaran atau persegi panjang yang tertanam di jalan.



**Gambar 7 Contoh Data D50**

### Preprocessing Techniques

Untuk meningkatkan kegunaan dataset ini pada YOLOv8, dilakukan beberapa langkah pra-pemrosesan berikut:

- **Object Isolation:** Setiap instance kerusakan diisolasi menggunakan bounding box, secara efektif menghilangkan gangguan latar belakang yang tidak relevan.
- **Normalization:** Dimensi gambar distandarisasi menjadi 640x640 piksel untuk memastikan kompatibilitas dengan arsitektur model.

Langkah-langkah pra-pemrosesan ini secara signifikan meningkatkan ekstraksi fitur, mengurangi waktu pelatihan model, dan meningkatkan akurasi deteksi. Penyesuaian metode pra-pemrosesan ini dengan rekomendasi dari [3][4] menyoroti peran pentingnya dalam mencapai kinerja yang skalabel dan andal.

### Evaluation Metrics

Evaluasi dilakukan berdasarkan metrik berikut:

- **Precision:** Proporsi prediksi positif yang benar dari total prediksi positif.
- **Recall:** Proporsi prediksi positif yang benar dari total kejadian positif.
- **F1-score:** Rata-rata harmonis dari presisi dan recall.
- **Mean Average Precision (mAP50-95):** Metrik komprehensif yang mengevaluasi kinerja model pada berbagai ambang batas IoU (Intersection over Union).

## 4. Methods

### YOLOv8 Architecture

YOLOv8 Nano, varian yang ringan namun sangat kuat, dipilih karena efisiensi sumber daya dan kinerjanya yang tinggi. Komponen utama dari arsitektur ini meliputi:

- **Conv Layers:** Berfungsi untuk mengekstraksi fitur dari gambar input.
- **C2f Blocks:** Memaksimalkan penggunaan memori dan komputasi secara efisien.
- **SPPF:** Lapisan pooling yang meningkatkan deteksi fitur multi-skala.
- **Detect Heads:** Menghasilkan bounding box, skor kepercayaan, dan prediksi kelas.

### Training Configuration

Pelatihan model menggunakan parameter berikut:

- **Pre-trained Weights:** Diinisialisasi dengan bobot dari dataset COCO untuk mempercepat konvergensi.
- **Batch Size:** 16 gambar per iterasi pelatihan, mengoptimalkan penggunaan memori.
- **Epochs:** 50 iterasi untuk memastikan pembelajaran yang komprehensif.
- **Optimizer:** AdamW dengan penyesuaian otomatis pada laju pembelajaran untuk pembaruan yang konsisten.
- **IoU Threshold:** Ditentukan sebesar 0.7 untuk memperbaiki prediksi bounding box.
- **Early Stopping:** Diaktifkan jika tidak ada peningkatan signifikan dalam 100 epoch terakhir.

Konfigurasi ini dirancang untuk menyeimbangkan antara kinerja dan efisiensi komputasi. Wawasan dari [3] sangat membantu dalam menyempurnakan parameter ini, memastikan keselarasan dengan praktik terbaik untuk pelatihan model yang dapat diskalakan.

## 5. Experiments

### Training Results

- **Duration:** 8 hours
- **Metrics:**
  - Precision: 84.4%
  - Recall: 88.7%
  - mAP50: 92.6%
  - mAP50-95: 91.1%

Fase pelatihan menunjukkan peningkatan yang konsisten di setiap epoch. Nilai mAP yang tinggi mengindikasikan pembelajaran fitur yang efektif, yang dapat dikaitkan dengan pra-pemrosesan objek terisolasi dan arsitektur YOLOv8 Nano yang tangguh.

### Validation Results

- **Metrics:**

- Precision: 84.4%
- Recall: 88.7%
- mAP50: 92.6%
- mAP50-95: 91.1%

Hasil validasi mencerminkan hasil pelatihan, menunjukkan overfitting yang minimal. Keselarasan antara kinerja pelatihan dan validasi menunjukkan kemampuan generalisasi model.

## Testing Results

- **Metrics:**
  - Precision: 89.1%
  - Recall: 86.7%
  - mAP50: 94.4%
  - mAP50-95: 92.9%

Fase pengujian menyoroti ketangguhan model terhadap data yang belum pernah dilihat sebelumnya, terutama dengan skor presisi dan mAP yang tinggi. Penurunan recall dibandingkan pelatihan dan validasi menunjukkan beberapa deteksi yang terlewat, yang mungkin disebabkan oleh contoh data uji yang menantang, seperti marka jalan yang pudar atau fitur yang sangat buram.

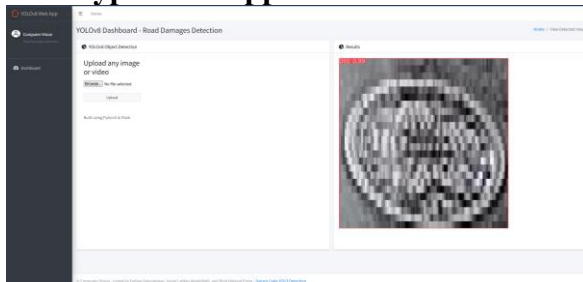
## Analysis of Results

Variasi kecil dalam presisi, recall, dan mAP pada pelatihan, validasi, dan pengujian dapat dikaitkan dengan faktor berikut:

- **Keragaman Dataset:** Dataset uji mencakup contoh yang lebih kompleks, menantang kemampuan deteksi model.
- **Ketidakeimbangan Kelas:** Beberapa kelas, seperti D40 (Retakan Kecil), memiliki jumlah contoh yang lebih sedikit, yang memengaruhi kinerja.
- **Dampak Pra-pemrosesan:** Isolasi objek secara signifikan mengurangi noise, tetapi beberapa fitur halus dalam dataset uji mungkin terlewat.

Kinerja kuat model pada kelas seperti D10 (Retakan Melintang) dan D43 (Garis Marka Kabur) menunjukkan efektivitasnya dalam mendeteksi jenis kerusakan yang terdefinisi dengan baik. Namun, penyempurnaan lebih lanjut diperlukan untuk kelas yang kurang terwakili.

## Prototype Web Application




Gambar 8 Antarmuka Aplikasi Web Prototype

Model YOLOv8 yang telah dilatih berhasil diintegrasikan ke dalam prototipe aplikasi web. Aplikasi ini memungkinkan pengguna untuk mengunggah gambar kerusakan jalan yang terisolasi, dengan sistem memberikan hasil deteksi dan klasifikasi secara real-time. Implementasi ini menunjukkan penerapan praktis dan skalabilitas model.


## Visualizations

Visualisasi berikut memberikan representasi rinci tentang kinerja model dan perkembangan proses pelatihan serta validasi:


1. **Training Loss Curve:** Grafik ini menggambarkan pengurangan nilai loss selama epoch pelatihan, menyoroti efisiensi pembelajaran model. Penurunan konsisten pada kurva menunjukkan konvergensi yang stabil dan efektif terhadap solusi optimal.
2. **Precision-Recall Curve:** Grafik ini menunjukkan hubungan antara precision dan recall pada berbagai ambang batas kepercayaan. Visualisasi ini penting untuk memahami keseimbangan model antara akurasi (precision) dan sensitivitas (recall), terutama dalam mendeteksi berbagai jenis kerusakan jalan.
3. **F1 Score Curve:** Kurva ini menunjukkan skor F1 pada berbagai ambang batas kepercayaan, merepresentasikan rata-rata harmonik dari precision dan recall. Grafik ini membantu mengevaluasi kinerja keseluruhan model dalam situasi dengan kebutuhan keseimbangan yang tinggi antara mendeteksi positif sejati dan menghindari prediksi positif palsu.
4. **Confusion Matrix:** Matriks ini memberikan wawasan tentang kinerja klasifikasi untuk setiap kelas kerusakan jalan. Matriks ini menyoroti area kekuatan model, seperti kelas dengan deteksi tinggi, serta mengidentifikasi area yang memerlukan perbaikan, seperti kelas dengan tingkat kesalahan prediksi yang tinggi.




Gambar 9 Training dan Validation Results




**Gambar 10 Precision-Recall Curve pada Training dan Validation**




**Gambar 11 Precision-Recall Curve pada Testing**




**Gambar 12 F1 Score Curve pada Training and Validation**



**Gambar 13 F1 Score Curve pada Testing**



**Gambar 14 Confusion Matrix Normalized untuk Training dan Testing**



**Gambar 15 Confusion Matrix Normalized untuk Testing**

## 6. Conclusion

Proyek ini secara sukses mendemonstrasikan penerapan YOLOv8 untuk deteksi kerusakan jalan secara real-time. Teknik pra-pemrosesan, terutama isolasi objek, terbukti

sangat penting dalam meningkatkan precision dan recall model. Sistem ini mencapai **mAP50-95 sebesar 91.1%**, yang menunjukkan keefektifannya untuk skenario dunia nyata.

Meskipun hasilnya menjanjikan, tantangan tetap ada untuk beberapa kelas kerusakan, seperti **Retakan Kecil (D40)**. Penelitian di masa depan dapat mengeksplorasi:

- **Teknik Augmentasi Lanjutan:** Untuk menangani ketidakseimbangan kelas dan meningkatkan generalisasi.
- **Fungsi Loss Berbobot Kelas:** Untuk memperkuat pembelajaran untuk kelas yang kurang terwakili.
- **Dataset yang Lebih Luas:** Untuk memvalidasi ketangguhan model pada kondisi jalan yang lebih beragam.

Integrasi model ini ke dalam prototipe aplikasi web menandai langkah signifikan menuju implementasi praktis. Implementasi ini memungkinkan pihak berwenang dan tim pemeliharaan untuk mengoptimalkan inspeksi jalan, secara signifikan mengurangi tenaga kerja manual dan biaya terkait. Selain itu, skalabilitas sistem ini menunjukkan potensinya untuk diadaptasi pada tugas terkait infrastruktur lainnya, seperti inspeksi jembatan dan pemeliharaan rel kereta api.

Temuan ini memperkuat pentingnya sistem deteksi kerusakan otomatis dalam perencanaan kota dan manajemen transportasi. Dengan memanfaatkan kemampuan YOLOv8 dan dataset yang telah diproses sebelumnya, proyek ini menawarkan solusi pemeliharaan jalan yang dapat diskalakan, hemat biaya, dan berkinerja tinggi. Integrasi ke dalam platform seluler atau web dapat semakin memperluas manfaatnya, berkontribusi pada infrastruktur transportasi yang lebih aman dan efisien di seluruh dunia.

## References

- [1] Arya, D., et al. *Global road damage detection: State-of-the-art solutions*. IEEE, 2020.
- [2] Arya, D., et al. *Deep learning-based road damage detection*. Automation in Construction, 2021.
- [3] Naddaf-Sh, S., et al. *An efficient and scalable deep learning approach for road damage detection*. IEEE, 2020.
- [4] Angulo, A., et al. *Road damage detection acquisition system*. Springer, 2019.
- [5] Rateke, T., et al. *Road surface detection and differentiation considering surface damages*. Autonomous Robots, 2021.
- [6] Arya, D., et al. *RDD2020: Annotated image dataset for road damage detection*. Data in Brief, 2021.
- [7] Tam, E. *Road Damages Detection Dataset*. Roboflow Universe, 2023.