

Deteksi Kerusakan Jalan Menggunakan YOLOv8

Farhan Faturahman
Universitas Telkom
Bandung, 40257 Indonesia
1301213188

Gevin Latifan Abduldjalil
Universitas Telkom
Bandung, 40257 Indonesia
1301213541

Rizal Hidayat Putra
Universitas Telkom
Bandung, 40257 Indonesia
1301213444

Abstract

Kerusakan jalan, seperti retakan, lubang, dan deformasi permukaan, memiliki dampak signifikan terhadap keselamatan transportasi dan biaya pemeliharaan jalan. Proyek ini mengatasi tantangan tersebut dengan menggunakan YOLOv8, sebuah kerangka kerja deteksi objek terkini, untuk mendeteksi dan mengklasifikasikan berbagai jenis kerusakan jalan. Dengan memanfaatkan dataset Road Damages Detection v7 yang telah diproses ulang dengan objek yang diisolasi, model kami menunjukkan presisi sebesar 84,4% dan recall sebesar 88,7%, serta mencapai skor Mean Average Precision (mAP50-95) sebesar 91,1%. Model ini juga diintegrasikan ke dalam prototipe aplikasi web, memungkinkan pengguna untuk mengunggah gambar kerusakan jalan yang terisolasi untuk dideteksi. Hasil ini menegaskan potensi sistem untuk aplikasi di dunia nyata, meningkatkan efisiensi inspeksi jalan dan mengurangi biaya pemeliharaan jangka panjang.

Keywords: Deteksi Kerusakan Jalan, YOLOv8, Deteksi Objek, Deep Learning, Pemeliharaan Infrastruktur

1. Introduction

Infrastruktur jalan merupakan komponen penting dalam mobilitas perkotaan dan pedesaan. Kerusakan seperti retakan, lubang, dan deformasi permukaan tidak hanya mengurangi tingkat keselamatan, tetapi juga meningkatkan biaya pemeliharaan jika tidak segera ditangani. Masalah ini dapat menyebabkan kecelakaan lalu lintas, peningkatan kerusakan kendaraan, dan waktu perbaikan yang lebih lama. Inspeksi manual, yang merupakan pendekatan tradisional, membutuhkan sumber daya yang besar, lambat, dan rentan terhadap kesalahan manusia. Keterbatasan ini mendorong kebutuhan akan sistem otomatis yang akurat dan efisien [1][2].

Kemajuan pesat dalam visi komputer dan pembelajaran mendalam telah membuka jalan bagi sistem deteksi kerusakan otomatis. Namun, banyak solusi yang ada menghadapi tantangan seperti inkonsistensi dalam dataset, biaya komputasi yang tinggi, dan keterbatasan skalabilitas.

Proyek ini bertujuan untuk mengatasi tantangan tersebut dengan menggunakan YOLOv8, sebuah kerangka kerja deteksi objek berbasis Convolutional Neural Network (CNN). Dengan memanfaatkan kemampuan pemrosesan waktu nyata dan dataset Road Damages Detection v7 yang telah diproses ulang, proyek ini bertujuan untuk mengembangkan solusi yang tangguh yang dapat:

- Mengotomatiskan deteksi kerusakan jalan dengan presisi dan recall yang tinggi.
- Meningkatkan efisiensi inspeksi infrastruktur.
- Menyediakan dasar untuk mengintegrasikan solusi otomatis ke dalam alur kerja pemeliharaan jalan.

YOLOv8 dipilih dibandingkan dengan model alternatif seperti Faster R-CNN dan SSD karena memiliki keseimbangan yang lebih baik antara kecepatan dan akurasi. Faster R-CNN, meskipun menawarkan presisi tinggi, memiliki waktu inferensi yang lebih lambat sehingga kurang cocok untuk aplikasi waktu nyata. Di sisi lain, SSD, meskipun lebih cepat, sering kali kurang optimal dalam mendeteksi objek kecil yang sangat penting dalam deteksi kerusakan jalan. Arsitektur YOLOv8 yang ringan dan ekstraksi fiturnya yang efisien menjadikannya pilihan optimal untuk proyek ini, terutama saat dipasangkan dengan dataset yang telah diproses untuk mengurangi noise dan meningkatkan akurasi deteksi. Keputusan ini sejalan dengan temuan studi sebelumnya yang menyoroti kemampuan YOLO dalam menangani dataset dengan variasi tinggi secara efektif [3][4].

Dataset Road Damages Detection v7 yang telah diproses ulang memainkan peran penting dalam memastikan kinerja deteksi yang tinggi dengan mengatasi ketidakseimbangan kelas dan noise. Teknik pemrosesan objek yang diisolasi pada dataset ini memungkinkan YOLOv8 untuk lebih fokus pada fitur kerusakan, meningkatkan efisiensi pembelajaran dan akurasi deteksi. Pemrosesan ini sesuai dengan temuan dari [3][4] yang menekankan pentingnya kualitas dataset dalam sistem deteksi yang skalabel dan efisien.

Paper ini menyajikan analisis mendalam tentang metodologi, eksperimen, dan hasilnya, menunjukkan implikasi praktis dari sistem yang diusulkan. Temuan ini menegaskan potensi penerapan teknologi ini untuk meningkatkan keselamatan transportasi dan mengurangi

biaya pemeliharaan jangka panjang.

2. Related Work

Deteksi kerusakan jalan telah menjadi topik penelitian yang semakin berkembang dalam beberapa tahun terakhir seiring dengan kemajuan teknologi pembelajaran mendalam. Beberapa kontribusi penting mencakup studi oleh Arya et al. [1], yang mengembangkan sistem deteksi kerusakan jalan global sebagai bagian dari tantangan Global Road Damage Detection Challenge (GRDDC) 2020. Tantangan ini memanfaatkan dataset besar yang terdiri dari 26.336 gambar jalan dari India, Jepang, dan Republik Ceko, dengan evaluasi model dilakukan pada dua set uji masing-masing berisi 2.631 dan 2.664 gambar. Model dengan kinerja terbaik menggunakan pendekatan pembelajaran ensemble berbasis YOLO, dengan F1 score sebesar 0,67 dan 0,66 pada dua set uji tersebut. Studi ini menjadi langkah signifikan dalam pengembangan metode deteksi kerusakan jalan yang lebih baik dan menetapkan tolok ukur untuk evaluasi di masa depan.

Dalam studi pelengkap lainnya, Arya et al. [2] mengeksplorasi metode berbasis pembelajaran mendalam untuk deteksi kerusakan jalan menggunakan dataset heterogen dari beberapa negara. Penelitian ini mengevaluasi penerapan model pemantauan jalan berbasis smartphone dari Jepang di wilayah lain dan mengusulkan dataset skala besar yang terdiri dari 26.620 gambar yang dikumpulkan dari India, Jepang, dan Republik Ceko. Dengan mengatasi tantangan biaya dan aksesibilitas, studi ini menyoroti potensi teknologi pembelajaran mendalam untuk pemantauan kondisi jalan, meskipun terdapat perbedaan kondisi jalan di berbagai wilayah.

Naddaf-Sh et al. [3] memperkenalkan pendekatan pembelajaran mendalam untuk evaluasi kondisi perkerasan jalan guna memfasilitasi pemeliharaan yang tepat waktu dan mencegah kerusakan infrastruktur lebih lanjut. Dataset yang digunakan mencakup berbagai jenis retakan jalan, seperti retakan longitudinal, transversal, dan aligator, yang diambil menggunakan perangkat seluler. Model yang diusulkan bersifat skala besar dan mencapai F1 score antara 52% hingga 56% dengan kecepatan inferensi 10–178 gambar per detik. Selain itu, studi ini menyajikan analisis kesalahan untuk mengidentifikasi keterbatasan model ketika dihadapkan pada variabilitas data.

Angulo et al. [4] menangani kebutuhan akan dataset yang seimbang dan representatif dengan menciptakan dataset kerusakan jalan skala besar yang mencakup 18.034 gambar dan 45.435 instance kerusakan. Studi ini mengevaluasi beberapa metode deteksi objek, termasuk MobileNet, RetinaNet, dan pendekatan tradisional seperti LBP-cascaded classifier. Temuan mereka menunjukkan kegunaan model ini dalam skenario dunia nyata, terutama untuk aplikasi berbasis mobile dan embedded.

Rateke et al. [5] menghadapi tantangan dalam

mendeteksi jalan dengan berbagai jenis permukaan, termasuk jalan yang rusak parah dan tidak beraspal. Dengan menggunakan arsitektur U-NET yang dipasangkan dengan ResNet34 dan pembelajaran transfer, studi ini menunjukkan bahwa kamera dengan biaya rendah dapat secara andal mengidentifikasi kerusakan jalan serta informasi permukaan lainnya yang penting untuk keselamatan berkendara. Pengenalan dataset ground truth baru lebih lanjut memvalidasi pendekatan mereka dalam skenario praktis.


Arya et al. [6] melanjutkan kontribusi mereka dengan menyoroti potensi model berbasis smartphone untuk pemantauan kerusakan jalan di negara berkembang. Dataset mereka yang terdiri dari 26.620 gambar dari beberapa negara menekankan pentingnya data heterogen untuk meningkatkan generalisasi model. Studi ini juga menawarkan rekomendasi kepada pemerintah daerah dan lembaga terkait untuk mengadopsi dataset dan model yang tersedia secara publik untuk deteksi dan klasifikasi kerusakan jalan secara otomatis.

Meskipun banyak kemajuan yang telah dicapai, tantangan dalam mencapai kinerja tinggi pada berbagai dataset masih ada. Proyek ini melanjutkan penelitian tersebut dengan memanfaatkan dataset Road Damages Detection v7 yang telah diproses ulang untuk mengatasi ketidakseimbangan kelas dan noise dalam data pelatihan. Integrasi YOLOv8 lebih lanjut meningkatkan efisiensi dan kinerja deteksi dalam aplikasi dunia nyata.

3. Data

Dataset Overview

Dataset **Road Damages Detection v7**, yang bersumber dari **Roboflow Universe** [7], terdiri dari 3.506 gambar beranotasi yang mencakup tujuh kelas kerusakan jalan yang berbeda. **Gambar 1** memperlihatkan contoh dari masing-masing kelas kerusakan, disusun dalam dua baris untuk mempermudah pengamatan.



Gambar 1 Contoh Data dalam Dataset

(a)	(b)	(c)	
Longitudinal Crack (D00)	Pothole (D40)	Alligator Crack (D20)	
(d)	(e)	(f)	(g)
Transverse Crack (D10)	Cross Walk Blur (D44)	White Line Blur (D43)	Manhole Cover (D50)

Dataset ini terdiri dari tujuh kelas kerusakan yang berbeda, yang masing-masing merepresentasikan jenis kerusakan jalan tertentu. **D00 (Longitudinal Crack)** adalah retakan linier yang memanjang di sepanjang permukaan jalan, sedangkan **D10 (Transverse Crack)** menggambarkan retakan horizontal yang sering melintasi jalan. **D20 (Alligator Crack)** terdiri dari retakan yang

saling berhubungan dan menyerupai pola kulit aligator. **D40 (Pothole)** mengacu pada depresi atau lubang di permukaan jalan. **D43 (White Line Blur)** menangkap kasus tanda jalan yang kabur, sedangkan **D44 (Cross Walk Blur)** menyoroti penyeberangan pejalan kaki yang memudar. Terakhir, **D50 (Manhole Cover)** mengidentifikasi penutup lubang berbentuk lingkaran atau persegi panjang yang tertanam di jalan.

Untuk meningkatkan kesesuaian dataset terhadap model YOLOv8, langkah praproses menyeluruh diterapkan. Langkah ini meliputi normalisasi untuk menyeragamkan dimensi gambar dan isolasi objek untuk menghilangkan noise latar belakang yang tidak relevan. Teknik praproses ini memastikan ekstraksi fitur yang lebih kuat dan memfasilitasi pembelajaran yang lebih efisien dalam mendeteksi serta mengklasifikasikan kerusakan jalan.

Preprocessing Techniques

Agar dataset lebih sesuai untuk digunakan dalam model YOLOv8, beberapa teknik praproses diterapkan. Salah satu langkah utama adalah isolasi objek, di mana setiap instance kerusakan diisolasi dengan menggunakan bounding boxes untuk secara efektif menghapus noise latar belakang yang tidak relevan. Selain itu, dimensi gambar dinormalisasi menjadi 640x640 piksel, memastikan kompatibilitas dengan arsitektur model.

Teknik praproses ini memainkan peran penting dalam meningkatkan ekstraksi fitur, mengurangi waktu pelatihan model, dan meningkatkan akurasi deteksi. Penyesuaian teknik-teknik ini dengan rekomendasi dari studi sebelumnya [3][4] menekankan pentingnya pendekatan ini dalam mencapai kinerja deteksi kerusakan jalan yang skalabel dan andal.

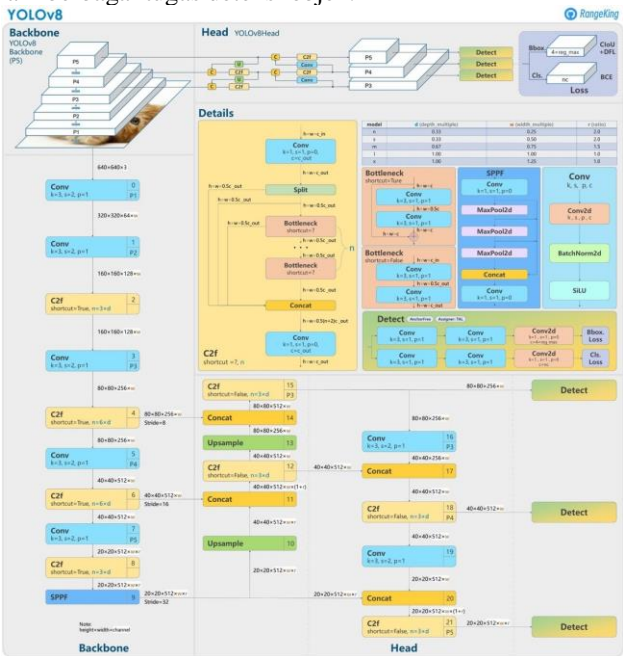
Evaluation Metrics

Evaluasi kinerja model dilakukan menggunakan beberapa metrik utama. Precision, yang didefinisikan sebagai proporsi true positive di antara semua prediksi positif, mengukur akurasi prediksi positif model. Recall, yang menunjukkan proporsi true positive di antara semua kejadian positif aktual, mengevaluasi kemampuan model untuk mendeteksi semua instance kerusakan jalan yang relevan. F1-score, yang dihitung sebagai rata-rata harmonik dari precision dan recall, memberikan penilaian yang seimbang terhadap kinerja model, terutama dalam menangani dataset yang tidak seimbang. Selain itu, Mean Average Precision (mAP50-95) digunakan sebagai metrik komprehensif untuk mengevaluasi kinerja pada berbagai ambang batas Intersection over Union (IoU), memberikan pemahaman lebih mendalam tentang kemampuan deteksi model pada tingkat overlap yang berbeda-beda. Metrik-metrik ini secara keseluruhan memberikan kerangka kerja yang andal untuk menilai efektivitas model YOLOv8 dalam mendeteksi dan mengklasifikasikan kerusakan jalan.

4. Methods

YOLOv8 Architecture

Arsitektur YOLOv8 terdiri atas tiga komponen utama: **Backbone**, **Neck**, dan **Head**. **Backbone** bertugas mengekstraksi fitur hierarkis dari gambar input, menangkap informasi visual penting pada berbagai skala. Fitur-fitur ini kemudian diteruskan ke **Neck**, yang mengagregasinya untuk meningkatkan kemampuan model dalam mendeteksi objek dengan ukuran yang bervariasi. Akhirnya, **Head** menghasilkan prediksi akhir, termasuk bounding box dan probabilitas kelas untuk objek yang terdeteksi. Desain arsitektur ini dirancang untuk efisiensi ekstraksi fitur dan deteksi objek, memastikan kinerja tinggi dalam berbagai tugas deteksi objek.



Gambar 2 Diagram Arsitektur YOLOv8

Dalam proyek ini, varian **YOLOv8 Nano** digunakan karena efisiensi sumber dayanya yang dioptimalkan tanpa mengorbankan kinerja. Konfigurasi ringan ini membuatnya sangat cocok untuk aplikasi real-time, terutama ketika sumber daya komputasi terbatas. Desain inovatif YOLOv8 memungkinkan pemrosesan dataset yang kompleks secara mulus, sehingga mendukung kemampuannya untuk mendeteksi dan mengklasifikasikan kerusakan jalan dengan akurasi tinggi. **Gambar 2** mengilustrasikan struktur arsitektur YOLOv8, menunjukkan komponen-komponennya dan perannya dalam proses deteksi.

Ketangguhan dan skalabilitas arsitektur ini juga didukung oleh kemajuan dalam lapisan konvolusi, blok penggabungan fitur, dan kepala deteksi, menjadikan YOLOv8 sebagai pilihan mutakhir untuk tugas deteksi objek. Pengaturan ini memastikan pelatihan yang efisien dan inferensi real-time, yang sangat penting untuk aplikasi

seperti deteksi kerusakan jalan.

Training Configuration

Pelatihan model **YOLOv8 Nano** dikonfigurasi dengan hyperparameter yang dioptimalkan untuk menyeimbangkan kinerja dan efisiensi komputasi. Tabel berikut merangkum hyperparameter utama yang digunakan dalam proyek ini:

Hyperparameter	Nilai	Deskripsi
Pre-trained Weights	COCO Dataset	Dimulai dengan bobot yang telah dilatih sebelumnya untuk mempercepat konvergensi.
Batch Size	16	Jumlah gambar yang diproses setiap iterasi pelatihan, mengoptimalkan penggunaan memori.
Epochs	50	Jumlah iterasi untuk memastikan pembelajaran yang komprehensif.
Optimizer	AdamW	Digunakan dengan penyesuaian otomatis learning rate untuk pembaruan yang konsisten.
IoU Threshold	0.7	Digunakan untuk meningkatkan keakuratan prediksi bounding box.
Early Stopping	100	Diterapkan jika tidak ada peningkatan signifikan dalam jumlah epoch yang ditentukan.

Konfigurasi ini dipilih secara cermat untuk mengikuti praktik terbaik dalam pelatihan model yang skalabel. Misalnya, penggunaan bobot yang telah dilatih sebelumnya dari dataset COCO mempercepat proses pelatihan dengan memanfaatkan pengetahuan sebelumnya. Batch size sebanyak 16 memberikan keseimbangan yang efisien antara penggunaan memori dan kecepatan pelatihan. Optimizer **AdamW** dipilih untuk memastikan pembaruan parameter model yang konsisten, sementara threshold IoU digunakan untuk meningkatkan akurasi prediksi bounding box. Implementasi early stopping mencegah overfitting dengan menghentikan pelatihan saat peningkatan kinerja sudah stagnan.

Wawasan dari penelitian sebelumnya, seperti yang dijelaskan dalam [3], sangat memengaruhi penyesuaian parameter ini, memastikan bahwa proses pelatihan berlangsung efisien dan efektif.

5. Experiments

Training, Validation, And Testing Results

Metrics	Training	Validation	Testing
Precision	84.4%	84.4%	89.1%
Recall	88.7%	88.7%	86.7%
mAP50	92.6%	92.6%	94.4%
mAP50-95	91.1%	91.1%	92.9%
Duration	8 hours	N/A	N/A

Fase pelatihan menunjukkan peningkatan yang konsisten di setiap epoch. Nilai mAP yang tinggi menunjukkan pembelajaran fitur yang efektif, yang dapat dikaitkan dengan preprocessing isolasi objek dan arsitektur YOLOv8 Nano yang kokoh.

Hasil validasi mencerminkan fase pelatihan, menunjukkan overfitting yang minimal. Keselarasan antara performa pelatihan dan validasi menunjukkan kemampuan generalisasi model yang baik.

Fase pengujian menyoroti ketangguhan model terhadap data yang belum pernah dilihat sebelumnya, khususnya dengan presisi tinggi dan skor mAP. Penurunan recall yang sedikit dibandingkan pelatihan dan validasi mengindikasikan beberapa deteksi yang terlewatkan, yang mungkin disebabkan oleh contoh yang menantang dalam set pengujian, seperti garis jalan yang pudar atau fitur kerusakan yang sangat buram.

Analysis of Results

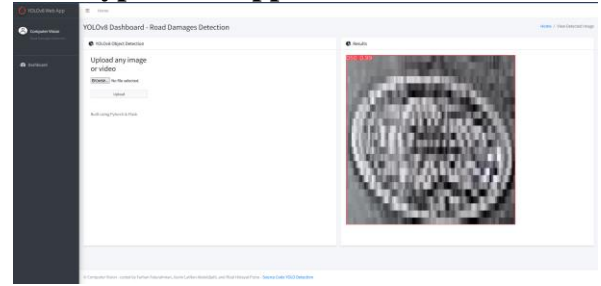
Fase pelatihan, yang selesai dalam waktu 8 jam, menunjukkan peningkatan konsisten pada metrik performa. Metrik validasi mencerminkan fase pelatihan, menyoroti overfitting yang minimal dan kemampuan generalisasi yang kuat. Fase pengujian menunjukkan kinerja yang solid pada data yang belum pernah dilihat sebelumnya, sebagaimana dibuktikan dengan mAP50-95 sebesar 92,9%. Variasi kecil dalam presisi dan recall diamati di seluruh dataset, yang dapat disebabkan oleh beberapa faktor berikut:

- **Keragaman Dataset:** Set pengujian mencakup contoh-contoh yang lebih kompleks, yang menantang kemampuan deteksi model.
- **Ketidakseimbangan Kelas:** Beberapa kelas, seperti D40 (Kerusakan Kecil), memiliki jumlah contoh yang lebih sedikit, yang memengaruhi performa.

- **Dampak Preprocessing:** Isolasi objek secara signifikan mengurangi noise, tetapi beberapa fitur halus dalam set pengujian mungkin terabaikan.

Hasil ini menyoroti kekuatan model dalam mendeteksi jenis kerusakan yang menonjol seperti retakan melintang dan tanda jalan yang buram, sambil mengungkap peluang untuk perbaikan lebih lanjut pada kelas yang kurang terwakili.

Prototype Web Application




Gambar 3 Pengguna Aplikasi Web Prototype

Model YOLOv8 yang telah dilatih berhasil diintegrasikan ke dalam prototipe aplikasi web. Aplikasi ini memungkinkan pengguna untuk mengunggah gambar kerusakan jalan yang telah diisolasi, di mana sistem akan memberikan hasil deteksi dan klasifikasi secara real-time. Implementasi ini menunjukkan potensi praktis dan skalabilitas model dalam aplikasi dunia nyata.

Visualizations

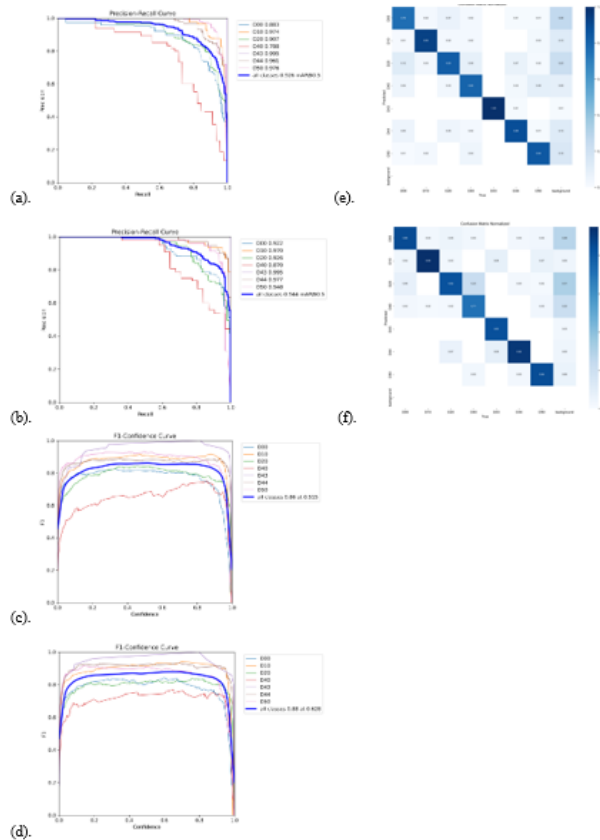
Visualisasi berikut memberikan representasi rinci tentang kinerja model dan perkembangan proses pelatihan serta validasi:

1. **Kurva Loss Pelatihan:** Grafik ini menggambarkan pengurangan loss selama 50 epoch pelatihan, menunjukkan efisiensi pembelajaran model YOLOv8 Nano. Kurva yang mulus mencerminkan stabilitas proses pelatihan dengan fluktuasi minimal yang menunjukkan tidak adanya overfitting atau ketidakstabilan.
2. **Kurva Precision-Recall:** Mengilustrasikan hubungan antara precision dan recall pada berbagai ambang kepercayaan. Kurva ini memberikan wawasan tentang keseimbangan keseluruhan model antara akurasi dan sensitivitas.
3. **Kurva F1 Score:** Menampilkan skor F1 di berbagai ambang batas, yang merepresentasikan rata-rata harmonis antara precision dan recall.
4. **Confusion Matrix:** Memberikan wawasan tentang kinerja klasifikasi untuk setiap kelas kerusakan, mengidentifikasi kekuatan dan area di mana misklasifikasi terjadi.



Gambar 4 Hasil Pelatihan dan Validasi

Kurva loss pelatihan menunjukkan pengurangan loss yang konsisten selama 50 epoch, menandakan pembelajaran yang efektif oleh model YOLOv8 Nano. Kurva yang halus menunjukkan stabilitas proses pelatihan dengan fluktuasi minimal, yang menunjukkan tidak adanya overfitting atau ketidakstabilan.



Gambar 5 Grafik Kurva dan Confusion Matrix
Gambar a: Kurva Precision-Recall untuk Pelatihan dan Validasi

Grafik ini menunjukkan hubungan antara precision dan recall pada berbagai ambang kepercayaan selama fase pelatihan dan validasi. Kurva yang hampir identik untuk kedua fase menegaskan kapasitas model untuk melakukan generalisasi dengan baik tanpa overfitting.

Gambar b: Kurva Precision-Recall untuk Pengujian

Kurva precision-recall untuk set pengujian menunjukkan sedikit penurunan dibandingkan dengan kurva pelatihan dan validasi. Hal ini mencerminkan tantangan yang dihadirkan oleh contoh-contoh yang belum terlihat di data pengujian, termasuk marka jalan yang pudar atau fitur kerusakan yang samar.

Gambar c: Kurva F1 Score untuk Pelatihan dan Validasi

Kurva F1 untuk pelatihan dan validasi menunjukkan pertumbuhan yang konsisten seiring meningkatnya ambang kepercayaan, yang menyoroti optimisasi model dalam menyeimbangkan precision dan recall selama fase ini.

Gambar d: Kurva F1 Score untuk Pengujian

Dalam fase pengujian, kurva F1 score menunjukkan kinerja yang stabil namun sedikit lebih rendah pada ambang kepercayaan yang lebih rendah. Perilaku ini menunjukkan penurunan sensitivitas, kemungkinan akibat keragaman dan kompleksitas set pengujian.

Gambar e: Confusion Matrix untuk Pelatihan dan Validasi

Confusion matrix untuk set pelatihan dan validasi menunjukkan nilai diagonal yang tinggi, yang mencerminkan kinerja yang kuat di semua kelas. Misklasifikasi kecil terkonsentrasi pada kelas yang kurang terwakili seperti D40 (Potholes).

Gambar f: Confusion Matrix untuk Pengujian

Untuk set pengujian, confusion matrix menunjukkan tingkat deteksi yang sangat baik untuk kelas yang terwakili dengan baik seperti D10 (Transverse Cracks) dan D43 (White Line Blur). Namun, kelas yang kurang terwakili seperti D40 dan D50 (Manhole Covers) menunjukkan tingkat deteksi yang lebih rendah, yang menunjukkan perlunya penyeimbangan dataset lebih lanjut atau augmentasi data.

6. Conclusion

Proyek ini berhasil menerapkan kerangka kerja deteksi objek YOLOv8 untuk deteksi kerusakan jalan secara real-time dengan memanfaatkan dataset **Road Damages Detection v7** yang telah diproses sebelumnya. Melalui isolasi objek dan normalisasi, sistem menunjukkan ekstraksi fitur yang andal, dengan capaian **mAP50-95** sebesar 91,1%. Hasil eksperimen menegaskan efektivitas model dalam mendeteksi berbagai jenis kerusakan, khususnya retakan melintang dan marka jalan yang buram, dengan tingkat overfitting yang minimal serta kemampuan generalisasi yang tinggi.

Pekerjaan di masa mendatang sebaiknya mengatasi tantangan ketidakseimbangan kelas dengan mengintegrasikan teknik augmentasi lanjutan dan fungsi loss berbobot kelas untuk meningkatkan performa pada kelas yang kurang terwakili, seperti retakan kecil dan penutup lubang got. Selain itu, memperluas dataset untuk

mencakup kondisi jalan yang lebih beragam akan lebih memvalidasi kekokohan model. Menjelajahi skalabilitas sistem untuk aplikasi infrastruktur lainnya, seperti deteksi kerusakan jembatan atau rel kereta api, dapat secara signifikan memperluas utilitas dan dampaknya.

References

- [1] Arya, D., et al. *Global road damage detection: State-of-the-art solutions*. IEEE, 2020.
- [2] Arya, D., et al. *Deep learning-based road damage detection*. Automation in Construction, 2021.
- [3] Naddaf-Sh, S., et al. *An efficient and scalable deep learning approach for road damage detection*. IEEE, 2020.
- [4] Angulo, A., et al. *Road damage detection acquisition system*. Springer, 2019.
- [5] Rateke, T., et al. *Road surface detection and differentiation considering surface damages*. Autonomous Robots, 2021.
- [6] Arya, D., et al. *RDD2020: Annotated image dataset for road damage detection*. Data in Brief, 2021.
- [7] Tam, E. *Road Damages Detection Dataset*. Roboflow Universe, 2023.